

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC THĂNG LONG



BÁO CÁO THỰC TẬP

PHÂN TÍCH VÀ XÁC ĐỊNH LỰA ĐÀO TUYỂN DỤNG

GIÁO VIÊN HƯỚNG DẪN: TRỊNH ĐỨC TÂN

SINH VIÊN THỰC HIỆN: TRẦN HUYỀN TRANG A46350

TẠ THU HẰNG A46078

NGUYỄN DUY ĐẠT A44441

NGUYỄN THỊ THÙY TRANG A46483

HÀ NỘI 2025

MỤC LỤC

LỜI MỞ ĐẦU	1
CHƯƠNG 1. VỊ TRÍ DATA ENGINEER.....	2
1.1. Giới thiệu.....	2
1.2. Data Engineer là gì?.....	2
1.3. Những công việc chính của Data Engineer	2
1.3.1. Thu thập và tổng hợp dữ liệu.....	2
1.3.2. Lưu trữ và tổ chức dữ liệu	3
1.3.3. Chuẩn hóa và làm sạch dữ liệu.....	4
1.3.4. Xây dựng Pipeline	4
1.3.5. Trích xuất dữ liệu.....	4
1.3.6. Đảm bảo chất lượng, hiệu suất và bảo mật dữ liệu	5
1.4. Những kỹ năng cần có đối với Data Engineer.....	5
1.4.1. Kỹ năng lập trình	5
1.4.2. Kiến thức về hệ thống cơ sở dữ liệu và kho dữ liệu.....	5
1.4.3. Kiến thức về hệ thống phân tán và đám mây	6
1.4.4. Kỹ năng về bảo mật dữ liệu.....	6
1.4.5. Kỹ năng thiết kế và trình bày báo cáo	7
1.4.6. Kỹ năng giao tiếp.....	7
1.4.7. Kỹ năng quản lý thời gian, sắp xếp công việc.....	7
1.4.8. Chăm trọng và tỉ mỉ	7
1.5. Tổng kết chương	8
CHƯƠNG 2. CỞ SỞ LÝ THUYẾT	9
2.1. Ngôn ngữ lập trình	9
2.1.1. Python.....	9
2.1.2. SQL.....	9

2.2. Hệ quản trị cơ sở dữ liệu.....	10
2.2.1. Cơ sở dữ liệu quan hệ (Relational Databases)	10
2.2.2. Cơ sở dữ liệu phi quan hệ (No SQL).....	10
2.3. Kho lưu trữ dữ liệu.....	11
2.4. Trực quan hóa và phân tích dữ liệu.....	11
2.5. Học máy.....	12
2.5.1. Khái niệm	12
2.5.2. Các mô hình học máy	12
2.5.3. Đánh giá mô hình	13
2.6. Tổng kết chương.....	15
CHƯƠNG 3. THU THẬP DỮ LIỆU.....	16
3.1. Nguồn dữ liệu	16
3.2. Cấu trúc dữ liệu khi thu thập.....	16
3.3. Phương pháp thu thập dữ liệu	16
3.3.1. Truy cập vào Facebook bằng Selenium.....	16
3.3.2. Đăng nhập vào Facebook bằng Selenium	17
3.3.3. Lấy thông tin bài đăng.....	17
3.3.4. Lưu dữ liệu vào file excel.....	21
3.3.5. Vòng lặp thu thập dữ liệu	22
3.4. Khó khăn trong quá trình thu thập dữ liệu.....	22
3.5. Tổng kết chương.....	23
CHƯƠNG 4. PHÂN TÍCH DỮ LIỆU	24
4.1. Trường dữ liệu được phân tích.....	24
4.1.1. Tài khoản	24
4.1.2. Vị trí.....	24
4.1.3. Nhóm ngành nghề.....	25
4.1.4. Lương	26

4.1.5. Thời gian làm.....	27
4.1.6. Hình thức nhận việc.....	27
4.1.7. Hình thức làm	27
4.1.8. Mô tả công việc	28
4.1.9. Nhân.....	28
4.1.10. Lí do.....	28
4.2. Khó khăn trong quá trình phân tích dữ liệu	29
4.3. Tổng kết chương	30
CHƯƠNG 5. XỬ LÝ DỮ LIỆU	31
5.1. Tiền xử lý dữ liệu	31
5.1.1. Lấy dữ liệu cần thiết	31
5.1.2. Loại bỏ cột không mang thông tin hữu ích.....	31
5.1.3. Kiểm tra giá trị thiếu.....	32
5.2. Mã hóa dữ liệu.....	33
5.2.1. Chuyển một số trường về nhị phân	33
5.2.2. Label Encoding.....	33
5.2.3. One-hot Encoding.....	34
5.3. Tổng kết chương	35
KẾT LUẬN.....	36

DANH MỤC BẢNG BIỂU

Bảng 1. Ma trận nhầm lẫn	13
Bảng 2. Nhóm ngành nghề và ngành nghề liên quan.....	26
Bảng 3. Số lượng cụ thể của các nhãn mục tiêu.....	31

DANH MỤC HÌNH ẢNH

Hình 1. Nút dropdown để chọn bộ lọc bình luận	18
Hình 2. Menu lọc bình luận.....	18
Hình 3. Dữ liệu trước và sau khi rà soát và bổ sung	32
Hình 4. Dữ liệu của cột “Nhóm ngành nghề” trước và sau khi mã hóa	34
Hình 5. Minh họa One-hot Encoding cho cột “Hình thức nhận việc”	35
Hình 6. Minh họa One-hot Encoding cho cột “Hình thức làm”	35

LỜI MỞ ĐẦU

Trong thời đại công nghệ số và sự phát triển mạnh mẽ của mạng xã hội, tuyển dụng trực tuyến đã trở thành một phương thức phổ biến, thuận tiện và nhanh chóng cho cả nhà tuyển dụng và người tìm việc. Tuy nhiên, sự bùng nổ của các nền tảng trực tuyến cũng kéo theo sự gia tăng đáng lo ngại của các hình thức lừa đảo tuyển dụng, gây thiệt hại về tài chính, tinh thần và thậm chí là an toàn cá nhân cho nhiều người lao động, đặc biệt là giới trẻ, sinh viên và thậm chí cả người trung niên.

Các đối tượng thường lợi dụng danh nghĩa tuyển dụng để thu thập thông tin cá nhân, chiếm đoạt tiền cọc, dụ dỗ làm việc bất hợp pháp hoặc khai thác lao động mà không trả lương. Hình thức này ngày càng tinh vi, được ngụy trang dưới dạng các bài đăng hấp dẫn, sử dụng tài khoản giả mạo hoặc thậm chí giả danh các doanh nghiệp thật. Việc nhận diện và phát hiện kịp thời các dấu hiệu lừa đảo là vấn đề cấp thiết trong bối cảnh hiện nay.

Xuất phát từ thực trạng đó, bài báo cáo này tập trung vào phân tích các đặc điểm nhận diện lừa đảo tuyển dụng trên nền tảng mạng xã hội, đặc biệt là Facebook – nơi có nhiều bài đăng tuyển dụng phi chính thống.

Với vai trò Data Engineer, tôi tập trung vào việc xây dựng pipeline thu thập và xử lý dữ liệu bài đăng tuyển dụng từ Facebook, bao gồm các bước: thu thập bài đăng, phân tích nội dung, gán nhãn, tiền xử lý văn bản, chuẩn hóa thông tin, loại bỏ trùng lặp, và mã hóa, tạo đặc trưng cho mô hình học máy.

CHƯƠNG 1. VỊ TRÍ DATA ENGINEER

1.1. Giới thiệu

Trong thời đại Công nghiệp 4.0, dữ liệu đang trở thành nguồn tài nguyên quý giá, thúc đẩy sự phát triển của hàng loạt công nghệ tiên tiến như Big Data, Trí tuệ nhân tạo (AI), Học máy (Machine Learning), ... Tuy nhiên, để những công nghệ này phát huy được hiệu quả, dữ liệu cần được thu thập, xử lý và tổ chức một cách khoa học ở quy mô lớn và phức tạp. Chính vì vậy, Data Engineer giữ vai trò quan trọng trong hệ sinh thái dữ liệu. Với nhiệm vụ xây dựng hạ tầng dữ liệu, thiết kế pipeline xử lý, và đảm bảo tính sẵn sàng của dữ liệu cho các hệ thống phân tích và học máy, Data Engineer đang trở thành một trong những vị trí được săn đón hàng đầu tại các công ty công nghệ.

1.2. Data Engineer là gì?

Data Engineer (Kỹ sư dữ liệu) là người xây dựng các hệ thống thu thập, phân tích, lưu trữ và chuyển đổi dữ liệu thô thành các thông tin hữu ích. Nhiệm vụ chính của DE là chuẩn hóa dữ liệu để hỗ trợ Data Scientists and Business Analysts tìm ra giải pháp cho các bài toán.

Tùy thuộc vào quy mô doanh nghiệp, phạm vi công việc của Data Engineer sẽ khác nhau, có thể tập trung vào việc xây dựng Data Pipeline, quản lý dữ liệu hoặc thực hiện nhiều nhiệm vụ khác nhau.

Không chỉ tập trung vào kỹ thuật, Data Engineer còn đóng vai trò quan trọng trong việc đề xuất giải pháp cải thiện chất lượng dữ liệu và phát hiện các xu hướng có giá trị cho doanh nghiệp. Khi tổ chức phát triển, khối lượng và độ phức tạp của dữ liệu tăng lên, kéo theo vai trò của kỹ sư dữ liệu ngày càng quan trọng trong việc đảm bảo tính minh bạch và chính xác của thông tin phục vụ ra quyết định.

1.3. Những công việc chính của Data Engineer

1.3.1. Thu thập và tổng hợp dữ liệu

Data Engineer là người thiết lập các kết nối để lấy dữ liệu từ nhiều nguồn khác nhau như hệ thống cơ sở dữ liệu, API, file log, dữ liệu từ website hoặc thiết bị IoT. Quá trình này là bước đầu tiên và quan trọng để đảm bảo có đủ dữ liệu phục vụ phân tích và ra quyết định.

– Công việc cụ thể:

+ Kết nối và lấy dữ liệu từ các nguồn nội bộ và bên ngoài (SQL, API, web, ...)

- + Tự động hóa việc thu thập dữ liệu để thu thập dữ liệu định kỳ, có thể là hàng ngày, hàng tuần....
- + Kiểm tra định dạng, cấu trúc dữ liệu đầu vào trước khi đưa dữ liệu vào hệ thống lưu trữ để đảm bảo tương thích với hệ thống.
- + Kết hợp dữ liệu từ nhiều nguồn khác nhau thành một dataset thống nhất. Dữ liệu từ các hệ thống khác nhau cần được chuẩn hóa để có thể sử dụng một cách hiệu quả.
- Các phương pháp thu thập dữ liệu phổ biến:
 - + Kết nối trực tiếp đến cơ sở dữ liệu rồi trích xuất dữ liệu: Dùng SQL (truy vấn cơ sở dữ liệu có cấu trúc) hoặc NoSQL (lấy dữ liệu từ các hệ thống phi cấu trúc) để truy vấn dữ liệu.
 - + Gọi API để truy xuất dữ liệu từ web, hệ thống SaaS, nền tảng mạng xã hội (Facebook, Google Analytics,...)
 - + Lấy dữ liệu được lưu dưới dạng file (csv, excel, json,...) trên file server.
 - + Sử dụng các công cụ như Selenium để thu thập dữ liệu từ giao diện website.
 - + Thu thập dữ liệu thời gian thực từ thiết bị IoT.

1.3.2. Lưu trữ và tổ chức dữ liệu

Sau khi thu thập dữ liệu, Data Engineer cần lưu trữ và tổ chức dữ liệu sao cho dễ dàng truy cập và sử dụng cho các mục đích khác nhau. Việc lưu trữ hợp lý và có tổ chức là nền tảng cho việc truy vấn nhanh, tiết kiệm chi phí và lựa chọn hệ thống phù hợp.

- Công việc cụ thể:
 - + Thiết kế cơ sở dữ liệu: Lựa chọn hệ thống csdl phù hợp (SQL hoặc NoSQL)
 - + Tối ưu hóa lưu trữ: Sử dụng các kỹ thuật tối ưu hóa như chỉ mục (indexing), phân vùng để cải thiện hiệu suất truy vấn.
 - + Dữ liệu lớn: Sử dụng các giải pháp phân tán như Hadoop, Spark để xử lý hệ thống dữ liệu có quy mô lớn.
- Công cụ phổ biến:
 - + Hadoop: Lưu trữ dữ liệu phân tán
 - + Amazon S3: Dịch vụ lưu trữ đám mây của AWS

- + Google BigQuery: Lưu trữ và phân tích dữ liệu lớn.

1.3.3. Chuẩn hóa và làm sạch dữ liệu

Dữ liệu từ nhiều nguồn thường không đồng nhất. Data Engineer có nhiệm vụ làm sạch, chuẩn hóa định dạng và chuyển đổi dữ liệu để đảm bảo tính nhất quán, từ đó đưa vào hệ thống lưu trữ dữ liệu tập trung.

– Công việc cụ thể:

- + Xử lý các giá trị thiếu: Các giá trị thiếu trong dữ liệu có thể được thay thế bằng các phương pháp như điền giá trị trung bình, giá trị mặc định hoặc bỏ qua các bản ghi không có giá trị.
- + Loại bỏ dữ liệu trùng lặp: Kiểm tra và loại bỏ các bản ghi trùng lặp để tránh ảnh hưởng đến kết quả phân tích.
- + Chuẩn hóa dữ liệu: Đảm bảo dữ liệu có định dạng nhất quán.
- + Kiểm tra tính hợp lệ của dữ liệu: Đảm bảo rằng dữ liệu không chứa các giá trị bất thường hoặc không hợp lệ.

1.3.4. Xây dựng Pipeline

Pipeline là một chuỗi các bước tự động để thu thập, xử lý và lưu trữ dữ liệu. Data Engineer xây dựng và vận hành pipeline (luồng xử lý dữ liệu) để đưa dữ liệu đi từ nguồn thô đến hệ thống lưu trữ hoặc phân tích một cách trơn tru, ổn định và có khả năng mở rộng.

– Công việc cụ thể:

- + Tạo quy trình tự động: Xây dựng các pipeline để tự động thu thập và xử lý dữ liệu.
- + Xử lý dữ liệu theo chu kỳ: Đảm bảo dữ liệu được thu thập và xử lý theo một lịch trình định kỳ (hàng giờ, ngày, tuần ...)
- + Quản lý các quy trình dài hạn: Đảm bảo rằng các pipeline được tối ưu hóa để xử lý khối lượng dữ liệu lớn một cách hiệu quả, nhanh và tiết kiệm tài nguyên.

1.3.5. Trích xuất dữ liệu

Dữ liệu sau khi được chuẩn hóa và lưu trữ, sẽ tiếp tục được xử lý để trích xuất đặc trưng, thông tin quan trọng, phục vụ trực tiếp cho các bộ phận phân tích, báo cáo hoặc đưa vào hệ thống AI.

- Công việc cụ thể:
 - + Viết truy vấn để lọc, phân loại, tính toán và tổng hợp dữ liệu.
 - + Cung cấp dữ liệu cho các phòng ban (Data Analysts/Data Scientists): Trích xuất dữ liệu đã được làm sạch, chuẩn hóa và có cấu trúc theo yêu cầu của các phòng ban.
 - + Xây dựng báo cáo: Tạo báo cáo cơ bản hoặc giúp tạo các bảng dữ liệu dùng cho phân tích, báo cáo.

1.3.6. Đảm bảo chất lượng, hiệu suất và bảo mật dữ liệu

Data Engineer cần đảm bảo rằng dữ liệu luôn sẵn sàng, được truy cập đúng cách, đúng người và được bảo mật trong suốt quá trình thu thập và xử lý.

- Công việc cụ thể:
 - + Đảm bảo chất lượng dữ liệu: Kiểm tra các chỉ số chất lượng dữ liệu như độ chính xác, đầy đủ và tính nhất quán.
 - + Tối ưu hóa hiệu suất: Đảm bảo các công việc thu thập và xử lý dữ liệu không làm giảm hiệu suất hệ thống.

Bảo mật dữ liệu: Thiết lập các biện pháp bảo vệ dữ liệu, mã hóa dữ liệu nhạy cảm và quản lý quyền truy cập người dùng.

1.4. Những kỹ năng cần có đối với Data Engineer

1.4.1. Kỹ năng lập trình

Một Data Engineer cần thành thạo các ngôn ngữ lập trình như Python, SQL để xử lý dữ liệu, tối ưu hóa quy trình, xây dựng pipeline và quản lý cơ sở dữ liệu.

Data Engineer cũng cần nắm được các kiến thức về các thư viện, công cụ hoặc framework hỗ trợ như Apache Spark, Hadoop, Dask, Pandas và các hệ thống quản lý dữ liệu lớn.

1.4.2. Kiến thức về hệ thống cơ sở dữ liệu và kho dữ liệu

Data Engineer cần có kiến thức về các hệ thống cơ sở dữ liệu để lưu trữ, quản lý và truy vấn dữ liệu hiệu quả.

- Cơ sở dữ liệu quan hệ (RDBMS): Các hệ quản trị cơ sở dữ liệu như MySQL, SQL Server là những công cụ cơ bản mà Data Engineer phải nắm vững để tạo, truy vấn và tối ưu hóa dữ liệu.

- Cơ sở dữ liệu NoSQL: Hiểu biết về các cơ sở dữ liệu NoSQL như MongoDB, Cassandra, CouchDB giúp xử lý các loại dữ liệu phi cấu trúc hoặc dữ liệu có quy mô lớn hơn, phân tán hơn.
- Kho dữ liệu (Data Warehousing): Là nơi lưu trữ các dữ liệu tích lũy từ nhiều nguồn khác nhau để phục vụ cho việc phân tích và ra quyết định. Các công cụ kho dữ liệu phổ biến như Amazon Redshift, Google BigQuery sẽ giúp tối ưu hóa việc lưu trữ và truy xuất dữ liệu.

1.4.3. Kiến thức về hệ thống phân tán và đám mây

Các hệ thống phân tán và đám mây là nền tảng quan trọng để xử lý và lưu trữ dữ liệu quy mô lớn. Data Engineer cần hiểu biết về:

- Hệ thống phân tán: Hiểu biết về các hệ thống phân tán giúp DE triển khai các giải pháp dữ liệu có thể xử lý hàng triệu, hàng tỷ bản ghi dữ liệu một cách hiệu quả và chịu tải cao. Các công cụ như Apache Hadoop và Apache Spark sẽ giúp xử lý dữ liệu phân tán trên các cụm máy tính.
- Công nghệ đám mây: Các dịch vụ đám mây cung cấp các công cụ để triển khai, lưu trữ và xử lý dữ liệu trên nền tảng đám mây. Các dịch vụ như Amazon S3, Google Cloud Storage, Azure Blob Storage hỗ trợ việc lưu trữ dữ liệu lớn, trong khi các dịch vụ tính toán như AWS Lambda, Google Cloud Functions hỗ trợ xử lý dữ liệu linh hoạt.

1.4.4. Kỹ năng về bảo mật dữ liệu

Bảo mật dữ liệu là một yếu tố cực kỳ quan trọng trong việc xử lý và quản lý dữ liệu, đặc biệt khi dữ liệu có thể chứa thông tin nhạy cảm hoặc thuộc quyền sở hữu trí tuệ của tổ chức. DE cần có các kỹ năng bảo mật như:

- Mã hóa dữ liệu: Biết cách mã hóa dữ liệu trong quá trình lưu trữ và truyền tải để bảo vệ dữ liệu khỏi các nguy cơ bị rò rỉ hoặc tấn công.
- Quản lý quyền truy cập: Sử dụng các phương pháp xác thực và phân quyền để đảm bảo rằng chỉ những người hoặc hệ thống có quyền truy cập mới có thể làm việc với dữ liệu.
- Tuân thủ các quy định bảo mật: Hiểu và tuân thủ các quy định bảo mật dữ liệu như GDPR (General Data Protection Regulation), HIPAA (Health Insurance Portability and Accountability Act), và các chuẩn bảo mật khác.

1.4.5. Kỹ năng thiết kế và trình bày báo cáo

Data Engineer không phải người trực tiếp phân tích dữ liệu nhưng DE vẫn cần có khả năng thiết kế, lập bảng báo cáo đơn giản để báo cáo kết quả cho cấp trên và các bộ phận khác. Việc thiết kế và trình bày báo cáo phải mang tính dễ hiểu, dễ đưa ra các nhận định so sánh. Các kỹ năng cần thiết bao gồm:

- Thiết kế báo cáo và Dashboard: Biết cách thiết kế các báo cáo đơn giản nhưng rõ ràng và dễ hiểu, đặc biệt là về các quy trình xử lý và hiệu suất hệ thống.
- Sử dụng công cụ báo cáo: Sử dụng các công cụ báo cáo và visualization như Tableau, Power BI, hoặc Grafana để trình bày dữ liệu một cách trực quan.

1.4.6. Kỹ năng giao tiếp

Data Engineer không chỉ làm việc với dữ liệu mà còn phải làm việc với nhiều nhóm khác nhau và các con số từ bảng báo cáo nghiên cứu rất phức tạp và khó hiểu đối với mọi người. Vì vậy, DE cần có kỹ năng giao tiếp, kỹ năng giải thích, thuyết trình để mang lại cái nhìn tổng quan cho những vấn đề nghiên cứu.

1.4.7. Kỹ năng quản lý thời gian, sắp xếp công việc

Công việc phân tích dữ liệu thường mất rất nhiều thời gian và trải qua nhiều giai đoạn phức tạp khác nhau. Một Data Engineer thường làm việc với nhiều dự án và yêu cầu xử lý dữ liệu từ nhiều nguồn khác nhau. Chính vì vậy, quản lý thời gian là rất quan trọng để hoàn thành dự án đúng hạn và hiệu quả.

- Quản lý ưu tiên: Biết cách ưu tiên các nhiệm vụ quan trọng và khẩn cấp để không bị chậm tiến độ.
- Sử dụng công cụ quản lý dự án: Làm quen với các công cụ như Trello, Asana để theo dõi tiến độ công việc và đảm bảo các dự án được triển khai đúng kế hoạch.

1.4.8. Cẩn trọng và tỉ mỉ

Trong công việc Data Engineering, việc xử lý dữ liệu đòi hỏi sự tỉ mỉ và cẩn thận để tránh sai sót. Một lỗi nhỏ trong việc xử lý hoặc truy vấn dữ liệu có thể gây ra kết quả sai lệch, ảnh hưởng đến toàn bộ quy trình hoặc quyết định của tổ chức.

- Kiểm tra và xác nhận dữ liệu: Cẩn thận kiểm tra tính toàn vẹn và độ chính xác của dữ liệu trước khi đưa vào hệ thống hoặc sử dụng trong các phân tích.

- Xử lý lỗi và khôi phục dữ liệu: Biết cách phát hiện và khôi phục lỗi khi xảy ra sự cố, đảm bảo dữ liệu luôn sẵn sàng và chính xác.

1.5. Tổng kết chương

Trong chương 1, báo cáo đã trình bày tổng quan về vị trí Data Engineer – một vai trò quan trọng đối với mảng dữ liệu hiện nay. Data Engineer không chỉ là người xây dựng hạ tầng lưu trữ và xử lý dữ liệu, mà còn đóng vai trò then chốt trong việc đảm bảo chất lượng, tính sẵn sàng và hiệu suất của dữ liệu – phục vụ trực tiếp cho các hoạt động phân tích và ra quyết định. Báo cáo cũng đã làm rõ các nhóm công việc chính mà một Data Engineer thường đảm nhiệm như: thu thập, lưu trữ, chuẩn hóa, trích xuất dữ liệu và xây dựng pipeline.

Bên cạnh đó, chương này cũng điếm qua những kỹ năng quan trọng mà một kỹ sư dữ liệu cần trang bị, từ kỹ năng lập trình, hiểu biết về hệ thống dữ liệu và điện toán đám mây, cho đến khả năng trình bày, bảo mật và quản lý thời gian.

Những kiến thức nền tảng và kỹ năng nêu trên sẽ là cơ sở để triển khai các chương tiếp theo trong báo cáo – nơi vai trò của Data Engineer được thể hiện thông qua một bài toán thực tế: thu thập và phân tích dữ liệu tuyển dụng lừa đảo trên mạng xã hội.

CHƯƠNG 2. CỞ SỞ LÝ THUYẾT

2.1. Ngôn ngữ lập trình

2.1.1. Python

Python là ngôn ngữ lập trình phổ biến trong nhiều lĩnh vực như khoa học dữ liệu, trí tuệ nhân tạo, phát triển web, tự động hóa và nhiều lĩnh vực khác. Python có cú pháp đơn giản, dễ đọc và có hệ sinh thái lớn với hàng chục nghìn thư viện phong phú (như Pandas, NumPy, SQLite3). Python thường được sử dụng để viết các pipeline ETL, xử lý API, xử lý dữ liệu và tự động hóa quy trình.

- Một số đặc điểm nổi bật của Python:
 - + Dễ học, dễ sử dụng
 - + Đa mục đích: Python có thể dùng để phát triển Web, phân tích dữ liệu, kiểm thử phần mềm, xây dựng mô hình học máy, trí tuệ nhân tạo...
 - + Thư viện phong phú: Python có hàng chục nghìn thư viện giúp giải quyết hầu hết các bài toán kỹ thuật.
 - + Đa nền tảng: Python chạy được trên nhiều hệ điều hành như Windows, macOS, Linux.

2.1.2. SQL

SQL (Structured Query Language) là ngôn ngữ truy vấn có cấu trúc, được sử dụng để giao tiếp và thao tác với cơ sở dữ liệu quan hệ (Relational Database). SQL là ngôn ngữ tiêu chuẩn giúp người dùng có thể truy xuất, thêm, sửa, xóa dữ liệu cũng như quản lý cấu trúc cơ sở dữ liệu.

- Chức năng chính của SQL:
 - + Tạo và quản lý bảng:

```
CREATE TABLE ... ( ) ;
```
 - + Truy vấn dữ liệu

```
SELECT ... FROM ... WHERE ...;
```
 - + Chèn dữ liệu

```
INSERT INTO ...  
VALUES ...;
```

- + Cập nhật dữ liệu

UPDATE ... SET ... WHERE...;

- + Xóa dữ liệu

DELETE FROM ... WHERE ...;

2.2. Hệ quản trị cơ sở dữ liệu

2.2.1. Cơ sở dữ liệu quan hệ (*Relational Databases*)

Cơ sở dữ liệu quan hệ là loại cơ sở dữ liệu lưu trữ dữ liệu theo dạng bảng (table) có cấu trúc gồm các hàng (record) và cột (field). Mỗi bảng đại diện cho một thực thể (entity), và các bảng có thể liên kết với nhau thông qua các khóa (key), tạo nên mối quan hệ giữa các dữ liệu.

– Đặc điểm:

- + Dữ liệu được lưu trữ theo dạng bảng có cấu trúc rõ ràng.
- + Sử dụng ngôn ngữ SQL để thao tác dữ liệu.
- + Mỗi bảng có một khóa chính (Primary Key) để định danh duy nhất các bản ghi.
- + Hỗ trợ các quan hệ giữa các bảng qua khóa ngoại (Foreign key).
- + Đảm bảo tính toàn vẹn của dữ liệu.
- + Phù hợp với các ứng dụng cần dữ liệu có cấu trúc rõ ràng, quan hệ phức tạp.

2.2.2. Cơ sở dữ liệu phi quan hệ (*No SQL*)

Cơ sở dữ liệu phi quan hệ là hệ thống quản lý dữ liệu không dựa trên mô hình bảng truyền thống của cơ sở dữ liệu quan hệ. Nó thường được thiết kế để lưu trữ và xử lý dữ liệu phi cấu trúc hoặc bán cấu trúc với khả năng mở rộng linh hoạt và hiệu suất cao trong môi trường dữ liệu lớn.

– Đặc điểm:

- + Không sử dụng bảng và quan hệ.
- + Dữ liệu được lưu dưới dạng tài liệu (Document Store), cặp key-value, đồ thị (Graph Database)...
- + Hỗ trợ khả năng mở rộng theo chiều ngang.

- + Bỏ qua tính toàn vẹn của dữ liệu, tập trung vào tính sẵn sàng và khả năng mở rộng.
- + Phù hợp với các ứng dụng cần xử lý lượng lớn dữ liệu đa dạng, dữ liệu phi cấu trúc hoặc cần tốc độ đọc ghi nhanh.

2.3. Kho lưu trữ dữ liệu

Kho dữ liệu là hệ thống dùng để tập trung, lưu trữ, bảo vệ và quản lý dữ liệu từ nhiều nguồn khác nhau trong một tổ chức. Kho dữ liệu có thể là một kho lưu trữ được kết nối mạng, kho lưu trữ phân tán trên đám mây, ổ cứng vật lý hoặc kho lưu trữ ảo. Nó có thể lưu trữ cả dữ liệu có cấu trúc và phi cấu trúc. Kho dữ liệu là nơi thực hiện quá trình trích xuất – chuyển đổi – tải dữ liệu để chuẩn bị cho phân tích, báo cáo hoặc xây dựng mô hình học máy.

Các loại kho lưu trữ phổ biến:

- Data Warehouse (kho dữ liệu): Là một hệ thống lưu trữ dữ liệu đã được xử lý và tổ chức có cấu trúc, được thiết kế đặc biệt để phân tích dữ liệu, thường phục vụ cho các mục tiêu phân tích, thống kê và báo cáo trong doanh nghiệp.
- Data Lake (hồ dữ liệu): Là kho lưu trữ tập trung cho tất cả dữ liệu, bao gồm dữ liệu có cấu trúc, bán cấu trúc và phi cấu trúc ở định dạng gốc.

2.4. Trực quan hóa và phân tích dữ liệu

Trực quan hóa và phân tích dữ liệu là cầu nối giữa dữ liệu thô và thông tin hữu ích cho doanh nghiệp.

Phân tích dữ liệu: Là quá trình khám phá, chuyển đổi, tổng hợp và diễn giải dữ liệu để rút ra thông tin hữu ích, hỗ trợ ra quyết định.

Trực quan hóa dữ liệu: Là quá trình sử dụng các yếu tố hình ảnh như đồ thị, biểu đồ hoặc bản đồ nhiệt để trình bày dữ liệu đã được phân tích. Trực quan hóa dữ liệu giúp người dùng xác định mối quan hệ giữa dữ liệu và phát hiện ra các mẫu hoặc xu hướng ẩn.

- Mục tiêu của trực quan hóa và phân tích dữ liệu:
 - + Khám phá dữ liệu: Hiểu phân bố, mối quan hệ giữa các biến, đặc trưng; phát hiện bất thường, dữ liệu thiếu hoặc lỗi nhập liệu.
 - + Giải thích và báo cáo: Trình bày kết quả phân tích cho các bên liên quan, tối ưu hóa báo cáo để hỗ trợ ra quyết định nhanh và chính xác.

- + Theo dõi hiệu suất: Xây dựng dashboard theo thời gian thực hoặc định kỳ để giám sát và cảnh báo khi vượt ngưỡng.

2.5. Học máy

2.5.1. Khái niệm

Học máy (Machine Learning) là một lĩnh vực con trong trí tuệ nhân tạo (AI) nghiên cứu về các thuật toán và mô hình giúp máy tính có khả năng học hỏi từ dữ liệu và cải thiện hiệu suất của mình mà không cần phải lập trình cụ thể. Thay vì sử dụng các quy tắc được lập trình sẵn, học máy cho phép máy tính tự động học và phát triển các quy tắc từ các mẫu dữ liệu.

2.5.2. Các mô hình học máy

- Học có giám sát: Dữ liệu huấn luyện đã được gắn nhãn. Mô hình học từ các cặp (input, output) để dự đoán giá trị đầu ra cho các dữ liệu mới. Các bài toán trong học có giám sát:
 - + Hồi quy (Regression): Dùng để dự đoán giá trị liên tục (ví dụ: dự đoán giá nhà, nhiệt độ, doanh thu).
 - + Phân loại (Classification): Dùng để phân loại các đối tượng vào các nhóm (ví dụ: phân loại email là spam hay không, phân loại bệnh nhân mắc bệnh).
 - + Mô hình tiêu biểu:
 - Hồi quy tuyến tính (Linear Regression)
 - Rừng quyết định (Random forest)
 - Mạng nơ-ron (Neural Networks)
- Học không giám sát:
 - + Clustering (Phân nhóm): Chia dữ liệu thành các nhóm sao cho các điểm dữ liệu trong mỗi nhóm có đặc điểm tương tự nhau.
 - + Giảm chiều (Dimensionality Reduction): Giảm số lượng đặc trưng trong dữ liệu trong khi vẫn giữ lại được thông tin quan trọng.
 - + Mô hình tiêu biểu: K-means, KNN
- Học tăng cường:
 - + Q-Learning: Một phương pháp học tăng cường không cần mô hình môi trường, học từ các hành động và phản hồi.

- + Deep Q-Network (DQN): Mô hình sử dụng mạng nơ-ron sâu để học các chính sách từ dữ liệu.

2.5.3. Đánh giá mô hình

- Confusion Matrix: Là một ma trận dùng để đánh giá hiệu suất của các mô hình phân loại. Nó cho thấy số lượng dự đoán đúng và sai trong từng lớp cụ thể. Cấu trúc của Confusion Matrix:
 - + True Positive (TP): Dự đoán đúng mẫu dương tính (mẫu thực sự là Positive và được dự đoán là Positive).
 - + True Negative (TN): Dự đoán đúng mẫu âm tính (mẫu thực sự là Negative và được dự đoán là Negative).
 - + False Positive (FP): Dự đoán sai mẫu dương tính (mẫu thực sự là Negative nhưng bị dự đoán là Positive).
 - + False Negative (FN): Dự đoán sai mẫu âm tính (mẫu thực sự là Positive nhưng bị dự đoán là Negative).

Actual\Predict	Positive	Negative
Positive	True Positive (TP)	False Negative (FN)
Negative	False Positive (FP)	True Negative (TN)

Bảng 1. Ma trận nhầm lẫn

- Accuracy
 - + Accuracy là chỉ số đo lường tỷ lệ dự đoán chính xác của mô hình phân loại. Nó được tính bằng cách chia tổng số dự đoán chính xác cho tổng số dữ liệu.
 - + Công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- Precision:
 - + Precision là chỉ số đo lường tỷ lệ dự đoán tích cực mà mô hình đã dự đoán chính xác. Nó được tính bằng cách chia tổng số dự đoán tích cực đúng cho tổng số dự đoán tích cực.

+ Công thức:

$$Precision = \frac{TP}{TP + FP}$$

– Recall

+ Recall là chỉ số đo lường tỷ lệ số trường hợp tiêu cực mà mô hình phân loại đúng. Nó được tính bằng cách chia tổng số trường hợp tiêu cực đúng cho tổng số trường hợp tiêu cực thực tế

+ Công thức:

$$Recall = \frac{TP}{TP + FN}$$

– F1-Score

+ F1 - Score là một phép kết hợp của precision và recall, và nó đại diện cho trung bình điều hoà giữa hai số đo này. Đại diện cho sự cân bằng giữa precision và recall.

+ Công thức:

$$F1_score = \frac{2 * Precision * Recall}{Precision + Recall}$$

– AUC-ROC

+ ROC (Receiver Operating Characteristic) → Là đồ thị biểu diễn mối quan hệ giữa TPR (True Positive Rate hay còn gọi là recall) và FPR (False Positive Rate) khi thay đổi ngưỡng (threshold) của mô hình.

+ AUC (Area Under the Curve) → Là diện tích dưới đường ROC, đại diện cho khả năng phân loại của mô hình.

+ Công thức:

$$FPR = \frac{FP}{FP + TN}$$

$$TPR = \frac{TP}{TP + FN}$$

2.6. Tổng kết chương

Chương 2 đã trình bày các kiến thức nền tảng phục vụ cho quá trình thu thập, xử lý và phân tích dữ liệu, bao gồm: ngôn ngữ lập trình Python và SQL; các hệ quản trị cơ sở dữ liệu quan hệ và phi quan hệ; kho lưu trữ dữ liệu; trực quan hóa – phân tích dữ liệu; và các kiến thức cơ bản về học máy. Những kiến thức này đóng vai trò quan trọng trong việc xây dựng hệ thống dữ liệu và đánh giá mô hình, làm nền tảng cho các bước thực nghiệm và phân tích.

CHƯƠNG 3. THU THẬP DỮ LIỆU

3.1. Nguồn dữ liệu

Dữ liệu được thu thập từ Facebook, cụ thể là từ các bài đăng tuyển dụng, các bình luận tuyển dụng bên dưới bài đăng tìm việc. Các bài đăng này được đăng tải trên các hội nhóm tìm việc trên Facebook, các hội nhóm này có số người tham gia đông.

3.2. Cấu trúc dữ liệu khi thu thập

Dữ liệu được cào từ Facebook về được lưu về dưới các trường sau:

- link: trường chứa đường dẫn trực tiếp đến bài tuyển dụng, bình luận tuyển dụng dưới bài tìm việc
- author: tác giả của bài tuyển dụng, bình luận tuyển dụng
- content: nội dung của bài tuyển dụng
- posted_time: thời gian dữ liệu được đăng tải
- crawl_time: thời gian dữ liệu được cào về

3.3. Phương pháp thu thập dữ liệu

Để thu thập dữ liệu từ các hội nhóm trên Facebook, tôi sử dụng ngôn ngữ Python kết hợp với thư viện Selenium, chạy trong môi trường PyCharm. Quy trình thu thập dữ liệu gồm các bước:

- Truy cập web Facebook
- Đăng nhập vào Facebook bằng Selenium
- Lấy thông tin bài đăng thông qua đường link đã được thu thập
- Lưu dữ liệu vào file excel

3.3.1. Truy cập vào Facebook bằng Selenium

Facebook không cung cấp API công khai cho việc truy cập nội dung trong các hội nhóm, do đó, tôi sử dụng Selenium – một thư viện tự động hóa trình duyệt để mô phỏng hành vi người dùng dựa trên WebDriver API hay còn gọi là giao diện web để giao tiếp với trình duyệt, cụ thể là đăng nhập và duyệt các nhóm Facebook như người dùng thật. Quy trình truy cập và đăng nhập được thực hiện như sau:

1. Khởi tạo trình điều khiển (WebDriver): Sử dụng hàm webdriver của thư viện selenium để mở trình duyệt Chrome

```
driver = webdriver.Chrome()
```

2. Truy cập trang Facebook: Trình duyệt tự động truy cập web Facebook qua lệnh:

```
driver.get("https://www.facebook.com/")
```

3.3.2. Đăng nhập vào Facebook bằng Selenium

Để có thể truy cập và lấy được nội dung trong các nhóm Facebook, tôi sử dụng Selenium để thực hiện quá trình đăng nhập. Tuy nhiên, trong quá trình triển khai, tôi nhận thấy rằng việc đăng nhập tự động mỗi lần truy cập một liên kết mới khiến phiên làm việc bị gián đoạn, thậm chí bị yêu cầu xác minh lại tài khoản. Điều này gây mất thời gian và tiềm ẩn nguy cơ bị Facebook phát hiện là bot.

Để khắc phục vấn đề trên, tôi chuyển sang sử dụng phương pháp đăng nhập bằng cookies. Cụ thể, tôi tạo một file cookies.py, file này thực hiện đăng nhập thủ công một lần duy nhất bằng trình duyệt được mở qua Selenium, sau đó lưu lại toàn bộ cookies phiên làm việc. Trong các lần truy cập sau, thay vì đăng nhập lại, chương trình tự động nạp cookies đã lưu, giúp trình duyệt duy trì trạng thái đã đăng nhập mà không cần thực hiện lại quá trình xác thực.

File cookies.py có code chi tiết như sau:

- Mở trình duyệt Chrome thông qua Selenium:

```
driver = webdriver.Chrome()
```

- Truy cập trang đăng nhập Facebook và yêu cầu người dùng đăng nhập thủ công

```
driver.get("https://www.facebook.com/login.php?next=/login")
```

- Lưu cookies sau khi đăng nhập thành công vào file có đuôi .pkl và đóng trình duyệt

```
with open('fb_cookies.pkl', 'wb') as f:
    pickle.dump(driver.get_cookies(), f)
driver.quit()
```

Phương pháp này không chỉ giảm thiểu rủi ro bị chặn truy cập từ Facebook mà còn giúp quá trình thu thập dữ liệu diễn ra nhanh và ổn định hơn.

3.3.3. Lấy thông tin bài đăng

Sau khi đăng nhập thành công, tôi cần truy cập vào các bài tuyển dụng, đăng tuyển được đăng trên Facebook và thu thập các nội dung tuyển dụng, các dữ liệu cần thiết.

Với các bài đăng tìm việc, tôi sử dụng Selenium để tự động thu thập toàn bộ bình luận của người dùng – người tuyển dụng. Quá trình này gồm 3 bước, tương ứng với 3 hàm:

- Chuyển chế độ lọc bình luận sang “Tất cả bình luận” – hàm


```
change_comment_filter_to_all
```

- + Khi truy cập vào bài viết, xác định nút dropdown để chọn bộ lọc bình luận (thông qua Xpath)

```
filter_button = driver.find_element (By.XPATH, link  
XPATH)
```

- + Cuộn đến vị trí đó và click để mở menu.


```
driver.execute_script(  
"arguments[0].scrollIntoView();", filter_button)  
filter_button.click()
```



Hình 1. Nút dropdown để chọn bộ lọc bình luận

- + Đợi menu hiện ra và click vào mục “Tất cả bình luận” thông qua XPATH

```
all_comments_option =  
wait.until(EC.element_to_be_clickable(  
    (By.XPATH, link XPATH) ))  
all_comments_option.click()
```



Hình 2. Menu lọc bình luận

- Mở toàn bộ bình luận (xem thêm bình luận) – hàm `show_all_comments`:
Hàm này sử dụng vòng lặp để hiển thị toàn bộ bình luận của bài viết. Vòng lặp này thực hiện các thao tác:

- + Dùng `find_elements` với để tìm kiếm các nút có nội dung bắt đầu bằng “Xem thêm” và chứa từ “bình luận”. Tôi sử dụng cách này bởi không phải tất cả bài viết đều có thể hiển thị thêm bình luận bằng button với nội dung “Xem thêm bình luận”. Nếu tôi đặt nội dung button là “Xem thêm bình luận” nhưng lại gặp nút có nội dung khác như: “Xem thêm 3 bình luận”, chương trình sẽ kết thúc vòng lặp và chuyển sang phần tiếp theo trong khi vẫn còn bình luận ẩn ở dưới.

```
buttons = driver.find_elements(By.XPATH,
    '//div[@role="button" and .//span[starts-with(text(),"Xem thêm") and contains(text(),"bình luận")]]')
```

- + Nếu không còn nút nào thì sẽ kết thúc vòng lặp.

```
if not buttons:
    break
```

- + Nếu còn thì cuộn đến nút đó, click và chờ 2 giây để bình luận hiển thị.

```
for btn in buttons:
    driver.execute_script(
        "arguments[0].scrollIntoView({behavior: 'smooth', block: 'center'});",
        btn)
    sleep(2)
    try:
        btn.click()
        sleep(2)
    except:
        continue
```

- Lấy nội dung bình luận – hàm `get_comments`:

- + Tìm tất cả các block bình luận bằng `find_elements`

```
comment_blocks = driver.find_elements(By.XPATH,
    '//div[@role="article"]')
```


+ Với mỗi block bình luận, tôi dùng `find_elements` để thu thập:

o Link dẫn đến bình luận (href chứa `comment_id=`)

```
try:
    comment_link_elem =
        block.find_element(By.XPATH,
            '._//a[contains(@href, "comment_id=")]')
    comment_link =
        comment_link_elem.get_attribute("href")
except:
    comment_link = ''
```

o Tên người bình luận (từ thẻ `span` chứa tên người bình luận)

```
try:
    author_elem = block.find_elements(By.XPATH,
        '._//span[@dir="auto" and
            not(ancestor::form)]')
    author = author_elem[0].text if author_elem
        else ""
except:
    author = ""
```

o Nội dung bình luận (từ thẻ `div` và nối các dòng lại)

```
try:
    content_elements =
        block.find_elements(By.XPATH,
            '._//div[@dir="auto" and
                not(ancestor::form)]')
    content = "\n".join([elem.text for elem in
        content_elements if elem.text.strip()])
except:
    content = ""
```

o Thời gian cào (lưu lại thời điểm chạy chương trình)

```
crawl_time = datetime.now().strftime(
    '%Y-%m-%d %H:%M:%S')
```

- + Lưu dữ liệu dưới dạng danh sách:

```
comments_data.append({
    'link': comment_link,
    'author': author,
    'content': content,
    'posted_time': posted_time,
    'crawl_time': crawl_time
})
```

3.3.4. Lưu dữ liệu vào file excel

Để tối ưu cho việc thu thập và lưu trữ dữ liệu, tôi đã viết hàm `save_output` có chức năng lưu dữ liệu đã được thu thập vào một file Excel (.xlsx). Nếu file đã tồn tại từ trước thì nó sẽ nối thêm dữ liệu mới vào file cũ.

- Hàm `save_output` nhận 2 tham số:

- + Danh sách các bình luận (`comments_data`)

- + Đường dẫn tới file Excel đầu ra

- Chuyển dữ liệu từ dạng list of dict (danh sách) sang DataFrame của Pandas để tiện xử lý và lưu

```
df_result = pd.DataFrame(data, columns=['link',
    'author', 'content', 'posted_time', 'crawl_time'])
```

- Nếu file Excel đã tồn tại:

- + Đọc dữ liệu cũ ra một DataFrame tạm

- + Ghép thêm dữ liệu mới vào phía sau và đánh lại chỉ số dòng để tránh bị lặp chỉ số.

```
if os.path.exists(output):
    old_df = pd.read_excel(output)
    new_df = pd.concat([old_df, df_result],
                        ignore_index=True)
```

- Nếu chưa có file Excel nào trước đó thì lưu dữ liệu được thu thập.

```
else:  
    new_df = df_result
```

- Lưu dữ liệu mới ra file Excel tại đường dẫn hàm nhận vào và trả về đường dẫn đó.

```
new_df.to_excel(output, index=False)  
return output
```

3.3.5. Vòng lặp thu thập dữ liệu

Trước tiên, tôi cần thu thập link của các bài đăng tuyển dụng, bài đăng tìm việc và lưu vào một file Excel.

Sau khi xây dựng đầy đủ các hàm để xử lý một bài viết cụ thể (bao gồm thu thập và lưu dữ liệu), tôi sử dụng vòng lặp để thu thập dữ liệu từ file Excel chứa link bài viết đã được thu thập trước đó. Vòng lặp này thực hiện quy trình sau:

- Truy cập đường dẫn được lưu trong file Excel
- Chuyển chế độ lọc bình luận sang “Tất cả bình luận”
- Hiện thị toàn bộ bình luận với nút “Xem thêm bình luận”
- Trích xuất thông tin của các bình luận (tên người đăng, nội dung, thời gian thu thập, và link)
- Lưu kết quả vào file Excel

Với cơ chế lặp như trên, tôi đã thu được file Excel chứa hơn 6000 dòng dữ liệu chưa được lọc về các bài đăng, bình luận tuyển dụng.

3.4. Khó khăn trong quá trình thu thập dữ liệu

- Việc thu thập trường “posted_time” gặp nhiều khó khăn do Facebook không hiển thị rõ ràng mốc thời gian này trong DOM hoặc hiển thị tương đối (ví dụ: “hôm qua”, “5 giờ trước”). Để lấy được thời gian chính xác, cần sử dụng Facebook Graph API. Tuy nhiên, Facebook API hiện không còn hỗ trợ truy cập rộng rãi như trước, yêu cầu tài khoản đã được Facebook cấp quyền truy cập – điều mà hầu hết các tài khoản cá nhân đều không thực hiện được. Do đó, trường “posted_time” không thể thu thập được thông qua “Selenium” và buộc phải loại bỏ trong quá trình xử lý dữ liệu.

- Cấu trúc DOM của Facebook không cố định. Chỉ cần một thay đổi nhỏ, các XPath hoặc selector trong code sẽ không còn hoạt động chính xác. Vậy nên cần điều chỉnh, cập nhật code thường xuyên.
- Facebook có cơ chế bảo mật cao, đặc biệt khi phát hiện hành vi truy cập tự động. Khi sử dụng Selenium, nếu để trình duyệt chạy quá lâu, tài khoản có thể bị yêu cầu đăng nhập lại. Để khắc phục điều này, tôi đã sử dụng cookie đăng nhập để duy trì trạng thái phiên, tránh phải đăng nhập lại liên tục.
- Trong quá trình thu thập hàng loạt bằng Selenium, đôi khi máy bị treo hoặc trình duyệt gặp lỗi và dừng giữa chừng. Điều này khiến quá trình thu thập dữ liệu bị gián đoạn, và có thể khiến các dữ liệu được thu thập trước đó không được lưu lại. Để khắc phục vấn đề này, tôi đánh dấu dòng đang xử lý (index). Mỗi khi thu thập xong một bài viết, tôi lưu lại thông tin về liên kết đã xử lý thành công. Khi chạy lại chương trình, tôi bỏ qua các link đã hoàn thành và tiếp tục thu thập từ dòng tiếp theo. Điều này giúp tiết kiệm đáng kể về thời gian và công sức.
- Một số link bài viết trong file danh sách không còn tồn tại do bị người dùng xóa hoặc tài khoản bị khóa dẫn đến việc không thể thu thập dữ liệu tại các link đó.
- Dữ liệu được thu thập chủ yếu dưới dạng văn bản tự do, không có cấu trúc chuẩn, có nhiều dữ liệu không mang thông tin tuyển dụng khiến việc tách, phân tích thông tin phải thực hiện thủ công.

3.5. Tổng kết chương

Trong chương 3 tôi đã trình bày quá trình thu thập dữ liệu tuyển dụng từ Facebook, một nền tảng mạng xã hội phổ biến với lượng lớn thông tin phi cấu trúc. Bằng việc sử dụng công cụ tự động hóa Selenium kết hợp với Python, dữ liệu từ các bài đăng và bình luận trong các hội nhóm tìm việc được cào về và lưu trữ có hệ thống. Để đảm bảo hiệu quả và tránh bị giới hạn truy cập, kỹ thuật sử dụng cookie đăng nhập và kiểm soát phiên làm việc được áp dụng. Ngoài ra, chương cũng đề cập đến các thách thức thực tế như thay đổi giao diện Facebook, xử lý lỗi, và chất lượng dữ liệu thu thập, từ đó cho thấy tầm quan trọng của việc xây dựng quy trình thu thập linh hoạt, có khả năng khôi phục và cập nhật.

CHƯƠNG 4. PHÂN TÍCH DỮ LIỆU

4.1. Trường dữ liệu được phân tích

Sau khi hoàn tất quá trình thu thập, tập dữ liệu ban đầu bao gồm 6.857 dòng, tương ứng với các bài đăng hoặc bình luận tuyển dụng được trích xuất từ các hội nhóm tuyển dụng trên Facebook.

Dữ liệu thu thập được cần phân tích thủ công thành các trường: Tài khoản, vị trí làm, nhóm ngành nghề, lương, thời gian làm, hình thức làm, hình thức nhận việc, mô tả công việc, nhân và lí do.

4.1.1. Tài khoản

Trường này xét xem tài khoản tuyển dụng có phải là tài khoản chính chủ hay là tài khoản giả mạo nhằm mục đích vừa đảo người tìm việc.

Các dấu hiệu của một tài khoản facebook giả mạo:

- Thông tin cá nhân không đáng tin cậy:
 - + Tên tài khoản mơ hồ, sử dụng tên nhân vật hoặc tên nước ngoài.
 - + Ảnh đại diện không thật: ảnh đại diện và ảnh bìa là ảnh nhân vật trong phim, ảnh người nổi tiếng hoặc ảnh về một người nào đó trên mạng.
 - + Thông tin tiểu sử không rõ ràng: không ghi nơi làm việc, nơi học tập hoặc có thông tin đến từ địa danh nào đó ở nước ngoài.
 - + Bạn bè trong danh sách thường ít, hoặc toàn người nước ngoài.
 - + Tài khoản mới lập gần đây hoặc lập đã lâu nhưng không có cập nhật gì kể từ lúc lập tài khoản.

4.1.2. Vị trí

Trường “Vị trí” thể hiện chức danh hoặc vị trí mà bài đăng đang tuyển dụng, chẳng hạn như:

- Nhân viên phục vụ
- Đóng gói hàng hóa
- Phụ bếp
- Tạp vụ
- Cộng tác viên (ctv)...

Thông tin này được trích xuất từ phần tiêu đề hoặc nội dung của bài viết, nơi người đăng sử dụng từ khóa nổi bật để thu hút ứng viên.

4.1.3. Nhóm ngành nghề

Có vô vàn tin tuyển dụng với rất nhiều vị trí như thu ngân cho siêu thị, thu ngân cho quán ăn, order, nhân viên phục vụ, nhân viên pha chế, phụ bếp.... Nếu liệt kê hết các vị trí làm thì rất khó cho việc phân tích và xây dựng mô hình. Vậy nên, tôi chọn nhóm các vị trí làm thành các nhóm ngành nghề. Cụ thể như sau:

Nhóm ngành nghề	Ngành nghề liên quan (ví dụ cụ thể)
Dịch vụ ăn uống	Nhân viên phục vụ, nhân viên quán ăn, pha chế, phụ bếp, bếp chính, thu ngân nhà hàng, nhân viên quán cafe, nhân viên trà sữa
Dịch vụ (nhảy cảm)	Nhân viên cho quán karaoke, bar, các bài đăng liên quan đến thu nợ
Bán hàng – Kinh doanh	Nhân viên bán hàng, thu ngân siêu thị, nhân viên shop thời trang, nhân viên cửa hàng tiện lợi, trưng bày sản phẩm, quản lý quầy
Lao động phổ thông	Giao hàng, bốc vác, dọn kho, vệ sinh công nghiệp, giúp việc, bảo vệ, tài xế xe ôm, phụ hồ
Văn phòng - Hành chính	Nhân viên văn phòng, nhập liệu, hành chính nhân sự, kế toán, lễ tân, trợ lý
Digital Marketing / Quảng cáo	Chạy quảng cáo Facebook/Google, SEO, quản trị fanpage, viết bài bán hàng, affiliate marketing, cộng tác viên bán hàng online
Nội dung số (Digital Content)	Streamer, Livestreamer, TikToker, Youtuber, video editor, content creator, viết kịch bản, quản trị kênh TikTok/YouTube

Giáo dục - Gia sư - Đào tạo	Gia sư, giáo viên tiếng Anh, trợ giảng, giáo viên online, đào tạo kỹ năng mềm
Dịch vụ lưu trú	Các công việc liên quan đến lưu trú, homestay, ở, ngủ nghỉ...
Dịch vụ	Các công việc liên quan đến du lịch, chăm sóc tóc, nail, spa, chăm sóc sắc đẹp
Tư vấn - Chăm sóc khách hàng	Tư vấn viên, chăm sóc khách hàng online, telesales, tổng đài viên, CSKH livestream
Y tế	Các công việc liên quan đến y, dược, khám chữa bệnh.
Unknow	Việc làm không mô tả rõ, thu nhập cao không yêu cầu kỹ năng, tuyển dụng gấp không ghi cụ thể công việc

Bảng 2. Nhóm ngành nghề và ngành nghề liên quan

4.1.4. Lương

Trường này ghi lại lương của các bài đăng tuyển dụng. Có rất nhiều bài đăng tuyển nhiều vị trí với các mức lương khác nhau, cũng có vị trí được tuyển với nhiều mức lương (lương full time và lương part time). Do vậy, cần chuẩn hóa lương về cùng một chuẩn. Trong bài báo cáo này, tôi chuẩn hóa lương về tiền lương theo giờ làm.

Đối với các bài đăng không ghi rõ lương hoặc giờ làm, hoặc chỉ ghi lương tháng, tôi quy chuẩn lương bằng cách chia tổng lương theo tháng cho 208. 208 là con số ước lượng số giờ làm việc trong một tháng tiêu chuẩn theo quy định của Bộ luật Lao động 2019. Cụ thể theo quy định tại Khoản 1, Khoản 2, Điều 105 Bộ luật Lao động 2019, thời giờ làm việc bình thường của người lao động tại Việt Nam không quá 8 giờ trong một ngày và 48 giờ trong một tuần. Vậy số giờ làm việc trong một tháng được tính bằng:

$$\begin{aligned}
&= \text{Số giờ làm việc mỗi tuần} * \text{Trung bình số tuần làm việc mỗi tháng} \\
&= 48 * 4.33 \\
&= 207.84 = 208
\end{aligned}$$

Đối với những bài đăng không ghi cả mức lương và thời gian làm, tôi để trống cột lương. Mục đích là để chia ra phân tích theo hai hướng: Bài đăng có đề lương và không đề lương.

4.1.5. Thời gian làm

Trong quá trình phân tích, tôi nhận thấy có nhiều bài đăng chỉ tuyển nhân viên thời vụ tức người lao động chỉ làm trong một ngày duy nhất, hoặc một số ngày rất giới hạn trong tháng (ví dụ: hỗ trợ chạy sự kiện, phát tờ rơi, làm mẫu tóc...). Việc chuẩn hóa giờ làm theo tuần hoặc tháng sẽ gây ra chênh lệch lớn trong phân tích.

Vì vậy tôi lựa chọn phương án chuẩn hóa giờ làm theo số giờ làm trong một ngày. Cách làm này đảm bảo tính thống nhất và phản ánh đúng bản chất thời gian lao động của từng công việc.

Tất nhiên cũng có những công việc không ghi rõ giờ làm cũng như số ngày làm trong tháng. Đối với những bài đăng này, tôi chọn cách bỏ trống thay vì để một số giờ mặc định. Tương tự như với cột lương, việc bỏ trống giờ làm giúp tôi có thể phân tích theo hai hướng: bài đăng ghi rõ giờ làm và không ghi rõ giờ làm.

4.1.6. Hình thức nhận việc

Trường này ghi lại cách thức mà ứng viên dùng để liên lạc với nhà tuyển dụng, thường là liên lạc qua facebook, zalo, số ít liên lạc qua telegram hoặc gmail.

4.1.7. Hình thức làm

Trường “Hình thức làm” phản ánh cách thức mà ứng viên sẽ thực hiện công việc sau khi được tuyển, tức là làm việc tại nhà hay tại nơi cụ thể, theo thời gian toàn phần hay bán thời gian. Dựa vào nội dung mô tả công việc trong bài đăng, trường này được phân loại thành các nhóm sau:

- Online: Ứng viên làm việc từ xa, thường qua điện thoại, máy tính.
- Full time: Là hình thức làm việc toàn thời gian, thường là những công việc văn phòng – hành chính, thường kéo dài 8 tiếng/ngày trở lên.
- Part time: Là hình thức làm việc bán thời gian, thường dao động từ 3 đến 6 tiếng/ngày, có thể linh hoạt theo ca (ca sáng, ca tối). Đây là hình thức phổ biến với sinh viên hoặc người tìm việc làm thêm.
- Unknow: Bài đăng không nêu rõ thời gian làm hoặc sử dụng các cụm từ không xác định như “*làm khi rảnh*”, “*tự do thời gian*”, khiến cho việc phân loại hình thức làm không thể xác định chính xác.

4.1.8. Mô tả công việc

Trường này để đánh giá xem nội dung bài đăng có cung cấp đủ thông tin để ứng viên hiểu được công việc cụ thể mà mình sẽ làm hay không. Nói cách khác, đây là trường phản ánh mức độ rõ ràng, cụ thể của công việc được mô tả trong bài tuyển dụng. Ví dụ:

- Với bài đăng tuyển phục vụ: ứng viên sẽ có thể biết khi đi làm phục vụ, công việc chủ yếu sẽ là bưng bê, dọn bàn, ghi lại món khách gọi.
- Ngược lại, nếu bài viết chỉ ghi ngắn gọn như “tuyển nhân viên” thì ứng viên sẽ không biết rõ mình sẽ phải làm gì khi nhận việc.

Việc phân tích trường này giúp làm rõ liệu bài đăng có mang tính minh bạch, có dấu hiệu lừa đảo (do mơ hồ, thiếu thông tin) hay không. Trong nhiều trường hợp, các bài tuyển dụng mập mờ, không ghi rõ nhiệm vụ là dấu hiệu của lừa đảo tuyển dụng.

4.1.9. Nhãn

Cột “Nhãn” chứa nhãn mục tiêu của dữ liệu. Cột này có các giá trị: “Lừa đảo”, “Thật”, và “Unknow”.

- Lừa đảo: Bài đăng có dấu hiệu không minh bạch, có khả năng lừa đảo ứng viên.
- Thật: Bài đăng có đầy đủ thông tin về công việc, mức lương hợp lý và không yêu cầu cọc.
- Unknow: Bài đăng chưa đủ thông tin để đưa ra đánh giá chắc chắn, có thể cần xem xét thêm hoặc kiểm chứng thêm.

Việc gán nhãn được thực hiện hoàn toàn thủ công, dựa trên kinh nghiệm, dấu hiệu nhận biết và các tiêu chí được xác định trước (tiêu chí về tài khoản, lương, ...).

4.1.10. Lí do

Cột này dùng để ghi chú lại cơ sở hoặc dấu hiệu dẫn đến việc bài đăng được gán nhãn “Thật” hoặc “Lừa đảo”. Đây là những nhận xét mang tính chủ quan trong quá trình phân tích thủ công, nhằm phục vụ việc kiểm tra lại dữ liệu hoặc giải thích quyết định gán nhãn. Trường này không mang đặc trưng định lượng hoặc thống kê, nên không được sử dụng trực tiếp trong quá trình phân tích dữ liệu hay huấn luyện mô hình. Nó chỉ đóng vai trò tham khảo, hỗ trợ cho người phân tích để kiểm tra độ nhất quán và hợp lý của nhãn.

4.2. Khó khăn trong quá trình phân tích dữ liệu

- Khối lượng dữ liệu được thu thập về là rất lớn và không có công cụ trợ giúp phân tích, dẫn đến phải xử lý thủ công. Quá trình này mất rất nhiều thời gian và dễ xảy ra sai sót cũng như bỏ sót các dòng dữ liệu.
- Có rất nhiều bài đăng, bình luận tuyển dụng không mang lại thông tin hữu ích, chỉ có lời mời gọi hoặc người đăng chỉ trả lời về thông tin tuyển dụng thông qua việc nhắn tin, gây mất thời gian cho người ứng tuyển, cũng tiềm ẩn nguy cơ cao bị lừa do thông tin tuyển dụng không được công khai.
- Khó để xác định một bài đăng, bình luận là lừa đảo hay không chỉ dựa vào nội dung vì không phải tất cả các bài đăng đầy đủ thông tin đều là thật (các đối tượng có thể sao chép thông tin bài đăng tuyển dụng thật, chỉ thay đổi thông tin liên lạc để lừa đảo ứng viên) và không phải tất cả các bài đăng ngắn (thậm chí cả các bài đăng không chứa thông tin tuyển dụng đều là giả mạo).
- Về tài khoản, có nhiều tài khoản đăng tin tuyển dụng được để ở chế độ riêng tư hoặc khóa trang cá nhân dẫn đến không thể xác định được đó có phải là tài khoản chính chủ hay không.
- Về vị trí làm, có nhiều bài viết không ghi rõ chức danh hoặc dùng nhiều từ hoa mỹ dẫn đến khó xác định vị trí tuyển dụng. Một số bài tuyển nhiều vị trí cùng lúc.
- Có nhiều bài đăng tuyển dụng nhiều vị trí với nhiều mức lương và giờ làm khác nhau, cần tạo nhiều bản ghi cho các vị trí đó để giữ được các thông tin quan trọng trong tuyển dụng như cột “Lương” và “Giờ làm”.
- Về cột lương, không phải bài tuyển dụng nào cũng công khai lương hoặc ghi rõ mức lương. Trong nhiều trường hợp, người đăng sử dụng cách viết mơ hồ như “lương cao” hoặc “thu nhập hấp dẫn”, hoặc đưa ra khoảng lương không rõ ràng (ví dụ: từ 10-12 triệu). Vậy nên mức lương được phân tích trong bài chỉ mang tính tương đối và tham khảo, chưa phản ánh chính xác tuyệt đối về thu nhập thực tế từ công việc được mô tả.
- Cột hình thức làm và hình thức nhận việc: một công việc có thể tiếp nhận ứng viên nhiều hình thức như facebook, zalo, ... và chấp nhận nhiều hình thức làm (ví dụ cả full time và part time như nhân viên phục vụ). Vậy nên cần có phương án xử lý hợp lý cho hai cột này để tránh nhiễu dữ liệu hoặc sai cấu trúc.

4.3. Tổng kết chương

Chương này trình bày quy trình phân tích dữ liệu thu thập từ Facebook, tập trung vào việc trích xuất và chuẩn hóa các thông tin liên quan đến tuyển dụng như tài khoản đăng tin, vị trí việc làm, nhóm ngành nghề, mức lương, thời gian làm việc, hình thức làm và nhận việc, cùng với mô tả công việc và nhãn đánh giá. Việc phân tích được thực hiện hoàn toàn thủ công do đặc thù dữ liệu phi cấu trúc và tính đa dạng của nội dung bài đăng. Các tiêu chí nhận biết tài khoản giả mạo, đánh giá mức độ minh bạch của công việc, và gán nhãn "Thật" – "Lừa đảo" được áp dụng nhằm xây dựng tập dữ liệu có chất lượng phục vụ phân tích và huấn luyện mô hình. Tuy nhiên, quá trình này gặp nhiều khó khăn như thông tin không đầy đủ, cách diễn đạt mơ hồ, bài viết đa vị trí hoặc đa hình thức làm việc, dẫn đến yêu cầu xử lý linh hoạt và cẩn trọng trong mỗi bước phân tích.

CHƯƠNG 5. XỬ LÝ DỮ LIỆU

5.1. Tiền xử lý dữ liệu

5.1.1. Lấy dữ liệu cần thiết

Sau quá trình xử lý và phân tích các trường dữ liệu, tôi thu được 586 dòng dữ liệu. Tổng số 586 dòng dữ liệu được chia thành 3 nhãn mục tiêu với số lượng cụ thể như sau:

Nhãn	Số lượng
Lừa đảo	268
Thật	312
Unknow	6

Bảng 3. Số lượng cụ thể của các nhãn mục tiêu

Có thể thấy, nhãn “Unknow” không mang lại thông tin hữu ích cho bài toán nhận diện lừa đảo tuyển dụng này. Do đó, tôi sử dụng Python để lấy ra 580 dòng dữ liệu có nhãn “Thật” (312 dòng) và “Lừa đảo” (268 dòng) để tiến hành xử lý dữ liệu.

Tuy nhiên, trong quá trình xử lý, có một số bài đăng có nội dung tuyển dụng nhiều vị trí với các mức lương và thời gian làm khác nhau, những bài viết này được tách thành nhiều dòng dữ liệu riêng biệt để phục vụ việc phân tích chi tiết và chính xác hơn. Vì vậy nên không thể tránh khỏi có những dòng dữ liệu bị trùng lặp thông tin về các trường nội dung, tài khoản, hình thức làm, hình thức nhận việc, mô tả công việc và nhãn. Các dòng dữ liệu này xuất hiện nhiều lần, mà mỗi dòng lại tương ứng với một bài tuyển dụng nên có thể bị coi là spam, gây nhầm lẫn trong phân tích và huấn luyện mô hình.

5.1.2. Loại bỏ cột không mang thông tin hữu ích

Dữ liệu sau khi lọc gồm 580 dòng dữ liệu với 15 cột: “link”, “author”, “content”, “posted_time”, “crawl_time”, “Tài khoản”, “Nhóm ngành nghề”, “Lương”, “Thời gian làm”, “Hình thức nhận việc”, “Hình thức làm”, “Mô tả công việc”, “Nhãn” và “Lí do”.

- Cột “posted_time” do không lấy được thông tin nên giá trị của cả cột này là NaN. Do đó chúng tôi loại bỏ cột này.
- Các cột “link”, “Lí do” đều là kiểu Object. “link” là đường dẫn đến bài tuyển dụng, “Lí do” để giải thích tại sao dòng dữ liệu đó là lừa đảo. Cả hai cột đều không mang thông tin cần thiết cho việc xây dựng mô hình nên chúng tôi loại bỏ cả hai cột này.

5.1.3. Kiểm tra giá trị thiếu

Dữ liệu ban đầu được điền và phân tích thủ công nên không tránh khỏi được việc thiếu dữ liệu. Lần đầu tiên kiểm tra chúng tôi nhận thấy có khá nhiều dữ liệu bị thiếu, cụ thể như sau:

- Cột “Tài khoản” thiếu khá nhiều dữ liệu (72 dòng).
- Các cột “author”, “crawl_time”. “Nhóm ngành nghề”, “Hình thức nhận việc”, “Hình thức làm” và “Mô tả công việc” thiếu không nhiều (chỉ 1-2 dòng dữ liệu).
- Cột “Lương” và “Thời gian làm” cũng thiếu rất nhiều do có nhiều bài đăng không cung cấp đầy đủ thông tin.

author	1	author	0
content	0	content	0
crawl_time	1	Vị trí	1
Tài khoản	72	crawl_time	0
Nhóm ngành nghề	2	Tài khoản	0
Lương	185	Nhóm ngành nghề	0
Hình thức nhận việc	2	Lương	109
Hình thức làm	1	Thời gian làm	291
Mô tả công việc	1	Hình thức nhận việc	0
Nhãn	0	Hình thức làm	0
		Mô tả công việc	0
		Nhãn	0

Hình 3. Dữ liệu trước và sau khi rà soát và bổ sung

Tuy nhiên, số lượng dữ liệu không nhiều, chỉ có 580 dòng nên việc loại bỏ dữ liệu thiếu là việc mang tính rủi ro lớn, Hơn nữa, đây cũng là dữ liệu được lấy thủ công. Chúng tôi chọn rà soát lại các dòng dữ liệu thiếu và bổ sung thủ công các dữ liệu thiếu đó.

Có thể thấy mặc dù “Lương” và “Thời gian làm” thiếu rất nhiều dữ liệu, cụ thể cột “Lương” thiếu 18.8% và cột “Thời gian làm” thiếu 50.17% tổng dữ liệu, nhưng hai cột này đều là thông tin quan trọng trong bài toán lừa đảo tuyển dụng nên không thể loại bỏ hai cột này. Để phân tích một cách chính xác và chi tiết hơn, có thể tách ra phân tích giữa không có thông tin về lương và giờ làm với đầy đủ thông tin về hai cột đó.

5.2. Mã hóa dữ liệu

Dữ liệu được thu thập thủ công nên tất cả các cột đều thuộc kiểu Object, vậy nên cần mã hóa các trường dữ liệu đó để phù hợp cho phân tích và đưa vào mô hình.

5.2.1. Chuyển một số trường về nhị phân

Tôi sử dụng hàm map để chuyển các cột “Nhãn”, “Tài khoản” và “Mô tả công việc” về kiểu nhị phân 0 và 1.

- Cột “Nhãn” có hai giá trị là “Thật” và “Lừa đảo”.

```
map(lambda x: 0 if x == 'Thật' else 1)
```

+ 0 là nhãn “Thật”

+ 1 là nhãn “Lừa đảo”

- Cột “Tài khoản” và “Mô tả công việc” cũng đều có hai giá trị:

```
map(lambda x: 0 if x == 'Không' else 1)
```

+ 0 là “Không” tức là Tài khoản này không chính chủ và công việc này không được mô tả.

+ 1 là “Có” tức là người đăng bài tuyển dụng này là trang cá nhân chính chủ, công việc này được mô tả rõ ràng.

5.2.2. Label Encoding

Cột “Nhóm ngành nghề” có tới 16 nhóm ngành nghề khác nhau. Vậy nên chúng tôi đã chọn Label Encoding để mã hóa trường dữ liệu này. Cụ thể, tôi sử dụng LabelEncoder của thư viện sklearn để xử lý trường “Nhóm ngành nghề”.

```
from sklearn.preprocessing import LabelEncoder  
  
le = LabelEncoder()  
  
df_temp['Nhóm ngành nghề'] =  
    le.fit_transform(df_temp['Nhóm ngành nghề'])  
  
df_temp['Nhóm ngành nghề'].value_counts().sort_index()
```

Nhóm ngành nghề		Nhóm ngành nghề	
Bán hàng - kinh doanh	103	0	103
Bán hàng - kinh doanh, Dịch vụ lưu trú	1	1	1
Digital Marketing / Quảng cáo	8	2	8
Digital Marketing / Quảng cáo, Bán hàng - kinh doanh	1	3	1
Dịch vụ	15	4	15
Dịch vụ (nhạy cảm)	18	5	18
Dịch vụ lưu trú	14	6	14
Dịch vụ ăn uống	131	7	131
Dịch vụ ăn uống, Bán hàng - kinh doanh	1	8	1
Lao động phổ thông	56	9	56
Nội dung số	28	10	28
Tư vấn - chăm sóc khách hàng	11	11	11
Unknown	40	12	40
Văn phòng - hành chính	32	13	32
Văn phòng - hành chính, Nội dung số	2	14	2
Y tế	1	15	1

Hình 4. Dữ liệu của cột “Nhóm ngành nghề” trước và sau khi mã hóa

5.2.3. One-hot Encoding

Với hai cột “Hình thức làm” và “Hình thức nhận việc” thì không thể dùng Label Encoding được bởi một nội dung tuyển dụng, công việc có thể tuyển qua nhiều hình thức nhận việc khác nhau như zalo và cả facebook, hay có nhiều hình thức làm như chấp nhận cả fulltime, parttime và cả online. Chúng tôi sử dụng One-hot Encoding để mã hóa 2 cột này. Tôi dùng hàm MultiLabelBinarizer từ thư viện sklearn để mã hóa cho hai cột này rồi gộp chúng vào DataFrame chính, sau đó bỏ hai cột “Hình thức làm” và “Hình thức nhận việc” cũ đi. Đoạn code dưới đây minh họa cho One-hot Encoding của hai cột này, cụ thể là one-hot encoding cho cột “Hình thức nhận việc”:

```
from sklearn.preprocessing import MultiLabelBinarizer

labels_column = df_temp['Hình thức nhận việc']

mlb = MultiLabelBinarizer()

encoded = mlb.fit_transform(labels_column)
```

	Hình thức nhận việc - email	Hình thức nhận việc - facebook	Hình thức nhận việc - telegram	Hình thức nhận việc - zalo
0	0	0	0	1
1	0	0	0	1
2	0	1	0	1
3	0	1	0	0
4	0	1	0	0

Hình 5. Minh họa One-hot Encoding cho cột “Hình thức nhận việc”

	Hình thức làm - fulltime	Hình thức làm - online	Hình thức làm - parttime	Hình thức làm - unknow
0	0	0	1	0
1	1	0	0	0
2	1	0	1	0
3	1	0	1	0
4	1	0	1	0

Hình 6. Minh họa One-hot Encoding cho cột “Hình thức làm”

5.3. Tổng kết chương

Chương 5 trình bày quá trình xử lý dữ liệu nhằm chuẩn bị cho giai đoạn huấn luyện mô hình phát hiện lừa đảo tuyển dụng. Sau khi loại bỏ nhãn không phù hợp và lọc các dòng trùng lặp, dữ liệu còn lại gồm 580 dòng thuộc hai nhãn chính: “Thật” và “Lừa đảo”.

Các bước xử lý bao gồm:

- Loại bỏ cột không cần thiết như link, posted_time, và Lí do.
- Xử lý giá trị thiếu thông qua rà soát và điền thủ công do dữ liệu nhỏ và mang tính chất quan trọng.
- Mã hóa dữ liệu:
 - + Dùng map để chuyển các cột nhị phân như “Nhãn”, “Tài khoản”, và “Mô tả công việc” về dạng số.
 - + Dùng Label Encoding cho cột “Nhóm ngành nghề” để mã hóa các ngành nghề thành các giá trị số rời rạc.
 - + Dùng One-hot Encoding với MultiLabelBinarizer cho các trường có thể mang nhiều giá trị như “Hình thức làm” và “Hình thức nhận việc”.

Toàn bộ quy trình giúp chuẩn hóa dữ liệu về định dạng số, phù hợp để phân tích định lượng và huấn luyện mô hình học máy.

KẾT LUẬN

Trong bối cảnh các hình thức lừa đảo tuyển dụng ngày càng tinh vi và lan rộng trên mạng xã hội, đặc biệt là Facebook – nền tảng phổ biến với người tìm việc trẻ tuổi, việc phát hiện sớm và cảnh báo các bài đăng có dấu hiệu lừa đảo là vô cùng cấp thiết. Báo cáo này đã thực hiện một quy trình đầy đủ từ thu thập, phân tích, xử lý dữ liệu đến chuẩn bị dữ liệu cho bài toán nhận diện lừa đảo tuyển dụng.

Cụ thể:

- Dữ liệu được thu thập từ các hội nhóm tuyển dụng trên Facebook thông qua Selenium và xử lý tự động kết hợp thủ công, đảm bảo chất lượng dữ liệu đầu vào.
- Quá trình phân tích dữ liệu thủ công giúp trích xuất được các trường quan trọng như tài khoản, vị trí làm việc, hình thức làm, lương, thời gian làm việc,... phục vụ nhận diện lừa đảo.
- Dữ liệu sau xử lý gồm 580 dòng dữ liệu được mã hóa và chuẩn hóa đầy đủ, sẵn sàng đưa vào huấn luyện mô hình học máy.

Mặc dù còn một số khó khăn như dữ liệu không cấu trúc hoặc thiếu thông tin, kết quả thu được là một tập dữ liệu có nhãn, sẵn sàng cho phân tích và huấn luyện mô hình. Đây có thể là nền tảng ban đầu quan trọng để phát triển hệ thống hỗ trợ người tìm việc trong môi trường số hiện nay.

TÀI LIỆU THAM KHẢO

- [1] Chuyện Data Engineer. (2022). Kỹ sư dữ liệu và lộ trình trở thành data engineer (DE) với 4 bước. <https://viblo.asia/p/ky-su-du-lieu-va-lo-trinh-tro-thanh-data-engineer-de-voi-4-buoc-3RIL5AWgLbB>
- [2] AWS. (). Kho dữ liệu là gì? <https://aws.amazon.com/vi/what-is/data-warehouse/>
- [3] AWS. (). Trực quan hóa dữ liệu là gì? <https://aws.amazon.com/vi/what-is/data-visualization/>
- [4] CareerViet. (). Data Engineer là gì? Công việc và kỹ năng cần thiết đối với vị trí này. <https://careerviet.vn/vi/talentcommunity/wiki-career/data-engineer-la-gi-cong-viec-va-ky-nang-can-thiet-doi-voi-vi-tri-nay.35A51FA2.html>
- [5] TOPDev. (). Tuyển tập câu hỏi phỏng vấn Data Engineer mới nhất. <https://topdev.vn/blog/cau-hoi-phong-van-data-engineer/>
- [6] Kim Bình. (2023). Data Engineer là gì? Công việc và kỹ năng cần thiết đối với vị trí này. <https://tuoitre.vn/data-engineer-la-gi-cong-viec-va-ky-nang-can-thiet-doi-voi-vi-tri-nay-20230720142335839.htm>
- [7] ASL LAW. (2025). Quy định về thời giờ làm việc tại Việt Nam. <https://aslgate.com/vi/quy-dinh-ve-thoi-gio-lam-viec-tai-viet-nam/>
- [8] bambooHR. (2025). What Is FTE (Full-Time Equivalent)?. <https://www.bamboohr.com/resources/hr-glossary/fte-full-time-equivalent>
- [9] Tạp chí phổ biến và tham vấn pháp luật. (2025). Lừa đảo tuyển dụng online: Những chiêu thức ma quái, khôn lường. <https://phobienphapluat.vn/gia-danh-tuyen-dung-online-chieu-tro-lua-dao-ngay-cang-tinh-vi-a917.html>
- [10] VOV Tiếng nói việt nam. (2023). Những dấu hiệu của hành vi lừa đảo tuyển dụng qua mạng cần tránh "mắc bẫy". <https://vov.vn/xa-hoi/nhung-dau-hieu-cua-hanh-vi-lua-dao-tuyen-dung-qua-mang-can-tranh-mac-bay-post1066604.vov>
- [11] Thư viện pháp luật. (2022). 07 dấu hiệu nhận biết hành vi lừa đảo tuyển dụng qua mạng. <https://thuvienphapluat.vn/chinh-sach-phap-luat-moi/vn/chong-lua-dao/43736/07-dau-hieu-nhan-biet-hanh-vi-lua-dao-tuyen-dung-qua-mang>
- [12] Meta. (). Graph API. <https://developers.facebook.com/docs/graph-api/>
- [13] Uet Boo. (2018). Facebook Graph API. <https://viblo.asia/p/facebook-graph-api-maGK7mPMlj2>

- [14] Nguyễn Đình Long. (2022). Làm thế nào để crawl hết tất cả bài viết trên Group, Fanpage Facebook ?. <https://viblo.asia/p/lam-the-nao-de-crawl-het-tat-ca-bai-viet-tren-group-fanpage-facebook-ORNZqA23Z0n>
- [15] Selenium. (2025). The Selenium Browser Automation Project. <https://www.selenium.dev/documentation/>
- [16] Itviec Blog. (2023). Cookies: Định nghĩa, Cách hoạt động và Cách triển khai hợp pháp. <https://itviec.com/blog/cookies-la-gi/>
- [17] Alakh Sethi. (2025). One Hot Encoding vs Label Encoding in Machine Learning. <https://www.analyticsvidhya.com/blog/2020/03/one-hot-encoding-vs-label-encoding-using-scikit-learn/>
- [18] Cao Minh Ngoc. (2019). Feature Engineering (Phần 3): Feature engineering với dữ liệu dạng phân loại (Categorical Data). <https://viblo.asia/p/feature-engineering-phan-3-feature-engineering-voi-du-lieu-dang-phan-loai-categorical-data-GrLZDQx2lk0>